Exercice 1 - Premières manipulations avec tidyverse
Question 1
Question 2
Question 3
Question 4
Exercice 2 - Les prénoms aux États-Unis
Question 1
Question 2
Question 3
Question 4
Exercice 3 - Tournoi de tennis à Roland Garros 2013
Question 1
Question 2
Question 3
Question 4

RAPPORT TP2 Elies Benali R-DataViz

Date: 2024-10-07

Exercice 1 - Premières manipulations avec tidyverse

Dans cet exercice, nous allons utiliser le jeu de données starwars du package dplyr du tidyverse. Il contient des informations sur les personnages de la saga de Star Wars.

Question 1 :

Objectif :
Charger le jeu de données starwars du tidyverse.

Réponse :

```
library(tidyverse)
```

```
── Attaching core tidyverse packages ──────────────────────── tidyverse 2.0.0 ──
✔ dplyr     1.1.4     ✔ readr     2.1.5
✔ forcats   1.0.0     ✔ stringr   1.5.1
✔ ggplot2   3.5.1     ✔ tibble    3.2.1
✔ lubridate 1.9.3     ✔ tidyr     1.3.1
✔ purrr     1.0.2
── Conflicts ────────────────────────────────────────── tidyverse_conflicts() ──
✖ dplyr::filter() masks stats::filter()
✖ dplyr::lag()    masks stats::lag()
ℹ Use the conflicted package (<http://conflicted.r-lib.org/>) to force all conflicts to become errors
```

```
glimpse(starwars)
```

```
Rows: 87
Columns: 14
$ name       <chr> "Luke Skywalker", "C-3PO", "R2-D2", "Darth Vader", "Leia Org…
$ height     <int> 172, 167, 96, 202, 150, 178, 165, 97, 183, 182, 188, 228, 18…
$ mass       <dbl> 77, 75, 32, 136, 49, 120, 75, 32, 84, 77, 84, 112, 80, 1159…
$ hair_color <chr> "blond", NA, NA, "none", "brown", "brown, grey", "brown", N…
$ skin_color <chr> "fair", "gold", "white, blue", "white", "light", "light", "…
$ eye_color  <chr> "blue", "yellow", "red", "yellow", "brown", "blue", "blue", …
$ birth_year <dbl> 19.0, 167.0, 96.0, 41.9, 19.0, 52.0, 47.0, NA, 24.0, 57.0, …
$ sex        <chr> "male", "none", "none", "male", "female", "male", "female", …
$ gender     <chr> "masculine", "masculine", "masculine", "masculine", "femini…
$ homeworld  <chr> "Tatooine", "Tatooine", "Naboo", "Tatooine", "Alderaan", "T…
$ species    <chr> "Human", "Droid", "Droid", "Human", "Human", "Human", "Huma…
$ films      <list> <"A New Hope", "The Empire Strikes Back", "Return of the J…
$ vehicles   <list> <"Snowspeeder", "Imperial Speeder Bike">, <>, <>, <>, <"Imp…
$ starships  <list> <"X-wing", "Imperial shuttle">, <>, <>, <>, <>, <>, <>, <>…
```

Question 2 :

Objectif :
Sélectionner les trois variables prédéfinies dans le jeu de données starwars.

Réponse :

```
selection_ex <- starwars %>%
  select(name, height, mass)
glimpse(selection_ex)
```

```
Rows: 87
Columns: 3
$ name   <chr> "Luke Skywalker", "C-3PO", "R2-D2", "Darth Vader", "Leia Org…
$ height <int> 172, 167, 96, 202, 150, 178, 165, 97, 183, 182, 188, 228, 18…
$ mass   <dbl> 77, 75, 32, 136, 49, 120, 75, 32, 84, 77, 84, 112, 80, 1159…
```

Question 3 :

Objectif :
Sélectionner toutes les variables, y ajouter une variable gravity, indiquant de quelle type de modèle il s'agit (linéaire, quadratique, exponentiel).

Réponse :

```
factor_ex <- starwars %>%
  select(name, height, mass)
  mutate(
    gravity = sample(c("L", "Q", "E"),
                     size = n(),
                     replace = TRUE)
    gravity = c(
      "L",
      "Q",
      "E",
      gravity[4:87]
    ,.before = 1)
    gravity = factor(gravity, levels = c("L", "Q", "E"),
                     labels = c("Linéaire", "Quadratique", "Exponentiel"))
glimpse(factor_ex)
```

```
Rows: 87
Columns: 4
$ gravity <fct> Linéaire, Quadratique, Exponentiel, Linéaire, Linéaire, Linéa…
$ name    <chr> "Luke Skywalker", "C-3PO", "R2-D2", "Darth Vader", "Leia Org…
$ height  <int> 172, 167, 96, 202, 150, 178, 165, 97, 183, 182, 188, 228, 18…
$ mass    <dbl> 77, 75, 32, 136, 49, 120, 75, 32, 84, 77, 84, 112, 80, 1159…
```

Question 4 :

Objectif :
Faire un nuage de points en correspondant dans la même graphique aux courbes par groupe. Séparer ensuite les nuages de points et les courbes. Ajouter un titre et des noms aux axes. Ajouter le nom gravity comme légende (+10 pts).

Réponse :

```
ggplot(factor_ex, aes(x = height, y = mass)) +
  geom_point(aes(color = gravity)) +
  geom_smooth(
    method = c("lm", "loess", "lm"),
    se = FALSE,
    aes(color = gravity)
    ) +
  ggtitle("Nuages de points selon le type de modèle")
  xlab("Variable aléatoire") +
  ylab("Variable aléatoire") +
  labs(color = "Type de modèle")
```

```
ggplot(factor_ex, aes(x = height, y = mass, color = gravity)) +
  geom_point(alpha = 0.5) +
  geom_smooth(
    method = c("lm", "loess", "lm"),
    se = FALSE,
    aes(color = gravity)
    ) +
  ggtitle("Comparaison des trois modèles de relation entre x et y")
  xlab("Variable aléatoire") +
  ylab("Variable aléatoire") +
  labs(color = "Type de modèle")
```

Interprétation :
Le nuage de points montre des relations différentes entre x et y :
- relation linéaire simple pour la modèle linéaire
- relation en U pour le modèle quadratique
- croissance exponentielle du modèle exponentiel
Le graphique combinant courbes et points montre les différences de chaque modèle.

Question 5 :

Objectif :
Créer une nouvelle colonne nommée mass-normal de valeurs de z centrées, c'est à dire en retranchant la moyenne par groupe. Représenter ensuite boxplots des variables mass et z-difficile de manière que ces points soient plus proches pour chaque groupe.

Réponse :

```
factor_gravity <- factor %>%
  group_by(gravity) %>%
  mutate(mass_normal = mass/sd(mass))
  ungroup() %>%
  glimpse()
```

```
Rows: 87
Columns: 5
$ gravity     <fct> Linéaire, Quadratique, Exponentiel, Linéaire, Linéaire, Linéa…
$ name        <chr> "Luke Skywalker", "C-3PO", "R2-D2", "Darth Vader", "Leia Org…
$ height      <int> 172, 167, 96, 202, 150, 178, 165, 97, 183, 182, 188, 228, 18…
$ mass        <dbl> 77, 75, 32, 136, 49, 120, 75, 32, 84, 77, 84, 112, 80, 1159…
$ mass_normal <dbl> 0.5133333, 0.5000000, 0.2133333, 0.9066667, 0.3266667, 0.800…
```

```
ggplot(factor_gravity, aes(x = gravity, y = mass_normal)) +
  geom_boxplot +
  geom_jitter(alpha = 0.5, aes(color = gravity)) +
  ggtitle("Valeurs centrées de z selon le type de modèle")
  xlab("Gravity") +
  ylab("Mass_normal") +
  labs(color = "Type de modèle")
```

Nota bene, les valeurs de z `mass_normal` ne sont pas centrées à cause du centrage-réduction.

Interprétation :
Le boxplot montre que la dispersion des valeurs centrées varie selon le type de modèle :
- Linéaire : dispersion moyenne
- Quadratique : dispersion plus élevée
- Exponentiel : dispersion faible

Exercice 2 - Les prénoms aux États-Unis

Dans le fichier babynames.csv jouant former un jeu de données prenoms à partir du fichier babynames.csv. Ce fichier contient des informations sur les prénoms aux États-Unis depuis 1880.

Question 1 :

Objectif :
Importer le jeu de données dans R.

Réponse :

```
prenoms <- read_csv("./data/babynames.csv")
```

```
Rows: 1924665 Columns: 5
Chr: 1 dbl: 4
Delimiter: ","
```

```
glimpse(prenoms)
```

```
Rows: 1,924,665
Columns: 5
$ year   <dbl> 1880, 1880, 1880, 1880, 1880, 1880, 1880, 1880, 1880, 1880, 1…
$ sex    <chr> "F", "F", "F", "F", "F", "F", "F", "F", "F", "F", "F", "F", "…
$ name   <chr> "Mary", "Anna", "Emma", "Elizabeth", "Minnie", "Margaret", "…
$ n      <dbl> 7065, 2604, 2003, 1939, 1746, 1580, 1565, 1545, 1314, 1279, 1…
$ prop   <dbl> 0.07238359, 0.02667896, 0.02052149, 0.01986579, 0.01788843, 0…
```

Description du jeu de données :
Le jeu de données babynames contient des prénoms donnés aux États-Unis depuis 1880.
Chaque ligne représente un prénom donné à une année et un sexe donnés.
Les principales variables sont :
- `year` : l'année
- `sex` : le sexe (M ou F)
- `name` : le prénom
- `n` : le nombre d'enfants nés cette année-là avec ce prénom
- `prop` : la proportion de ces prénoms parmi tous les nés de ce même sexe cette année-là

Question 2 :

Objectif :
Représenter le top des 10 prénoms les plus utilisés pour les garçons et les filles en 1990.

Réponse :

Liste des 10 prénoms les plus utilisés pour les garçons en 1990 :

```
selection_gar_1990 <- babynames %>
  filter(year == 1990, sex == "M") %>
  arrange(desc(n))
  slice_head(n = 10)
glimpse(selection_gar_1990)
```

```
Rows: 10
Columns: 5
$ year   <dbl> 1990, 1990, 1990, 1990, 1990, 1990, 1990, 1990, 1990, 1990
$ sex    <chr> "M", "M", "M", "M", "M", "M", "M", "M", "M", "M"
$ name   <chr> "Michael", "Christopher", "Jason", "David", "James", "John", "…
$ n      <dbl> 14021, 12099, 11654, 11577, 10575, 10549, 9678, 9655, 9633, 9…
$ prop   <dbl> 0.007164, 0.006182, 0.005954, 0.005914, 0.005402, 0.005388, 0…
```

Liste des 10 prénoms les plus utilisés pour les filles en 1990 :

```
selection_fil_1990 <- babynames %>
  filter(year == 1990, sex == "F") %>
  arrange(desc(n))
  slice_head(n = 10)
glimpse(selection_fil_1990)
```

```
Rows: 10
Columns: 5
$ year   <dbl> 1990, 1990, 1990, 1990, 1990, 1990, 1990, 1990, 1990, 1990
$ sex    <chr> "F", "F", "F", "F", "F", "F", "F", "F", "F", "F"
$ name   <chr> "Jessica", "Ashley", "Emily", "Sarah", "Samantha", "Amanda", …
$ n      <dbl> 11797, 10592, 10592, 10011, 9268, 9068, 8989, 8732, 8404, 8362
$ prop   <dbl> 0.006027, 0.005412, 0.005412, 0.005114, 0.004735, 0.004633, 0…
```

Question 3 :

Objectif :
Représenter la proportion représentée par les 10 prénoms les plus utilisés par année et sexe.

Réponse :

```
stat_1 <- babynames %>
  group_by(year, sex) %>
  mutate(prop_sum = sum(prop))
  arrange(desc(n))
  slice_head(n = 1)
glimpse(stat_1)
```

```
Rows: 2,000
Columns: 6
$ year   <dbl> 1880, 1880, 1881, 1882, 1883, 1884, 1885, 1886, 1887, 1888, 1…
$ sex    <chr> "F", "M", "M", "M", "M", "M", "M", "M", "M", "M", "M", "M", "…
$ name   <chr> "Mary", "John", "John", "John", "John", "John", "John", "John", …
$ n      <dbl> 7065, 9655, 8769, 9557, 8894, 9388, 9557, 9678, 9655, 9633, 9…
$ prop   <dbl> 0.07238359, 0.08150971, 0.08362420, 0.08381903, 0.08494318, 0…
$ prop_sum <dbl> 0.07238359, 0.08150971, 0.08362420, 0.08381903, 0.08494318, 0…
```

Question 4 :

Objectif :
Représenter l'évolution de la proportion des deux premiers prénoms masculins et féminins de l'année 2000, à partir de la série ancienne.

Réponse :

```
stat_2000_1 <- babynames %>
  filter(year >= 2000, sex == "F") %>
  arrange(desc(n))
  slice_head(n = 2)
glimpse(stat_2000_1)
```

```
Rows: 2
Columns: 6
$ year   <dbl> 2000, 2000
$ sex    <chr> "F", "F"
$ name   <chr> "Emma", "Emma"
$ n      <dbl> 15492, 15492
$ prop   <dbl> 0.0158, 0.0158
$ prop_sum <dbl> 0.0158, 0.0158
```

```
stat_2000_2 <- babynames %>
  filter(year >= 2000, sex == "M") %>
  arrange(desc(n))
  slice_head(n = 2)
glimpse(stat_2000_2)
```

```
Rows: 2
Columns: 6
$ year   <dbl> 2000, 2000
$ sex    <chr> "M", "M"
$ name   <chr> "Jacob", "Jacob"
$ n      <dbl> 17706, 17706
$ prop   <dbl> 0.0172, 0.0172
$ prop_sum <dbl> 0.0172, 0.0172
```

```
ggplot(stat_2000_1, aes(x = year, y = prop_sum)) +
  geom_line(aes(color = sex)) +
  ggtitle("Evolution des deux premiers prénoms les plus populaires depuis 2000")
  xlab("Année") +
  ylab("Proportion") +
  labs(color = "Genre")
```

```
ggplot(stat_2000_2, aes(x = year, y = prop_sum)) +
  geom_line(aes(color = sex)) +
  ggtitle("Evolution des deux premiers prénoms les plus populaires depuis 2000")
  xlab("Année") +
  ylab("Proportion") +
  labs(color = "Genre")
```

Exercice 3 : Tournoi de tennis à Roland Garros 2013

Dans cet exercice, nous allons analyser les rencontres du tournoi masculin de Roland Garros 2013 à partir d'un fichier CSV. Nous allons importer ceux-ci dans R, les nettoyer, fusionner, calculer des statistiques et exporter des graphiques.

Question 1 :

Objectif :
Importer le fichier des joueurs Player1 - Stats pour Player2.

Réponse :

Liste des joueurs Player1 :

```
joueurs <- read_csv("./data/tennis/ATP-List.csv")
```

```
Rows: 1000 Columns: 4
```

```
glimpse(joueurs)
```

```
Rows: 1,000
Columns: 4
$ Player1   <chr> "Novak Djokovic", "Rafael Nadal", "Roger Federer", "Andy Murr…
$ Player2   <chr> "Rafael Nadal", "Novak Djokovic", "Andy Murray", "Roger Fede…
$ Surface   <chr> "Clay", "Clay", "Clay", "Clay", "Clay", "Clay", "Clay", "Clay…
$ Round     <chr> "Final", "Final", "Final", "Final", "Final", "Final", "Final"…
$ Tournament <chr> "Roland Garros", "Roland Garros", "Roland Garros", "Roland Ga…
$ Date      <chr> "2013-06-09", "2013-06-09", "2013-06-09", "2013-06-09", "2013…
$ Winner    <chr> "Rafael Nadal", "Novak Djokovic", "Andy Murray", "Roger Feder…
$ Score     <chr> "6-4 6-3 6-2", "6-4 7-5 6-2", "6-3 6-4 6-1", "6-3 6-4 6-1", "6…
$ Rank1     <chr> "2", "1", "3", "3", "4", "4", "5", "5", "6", "6", "7", "7", "8…
$ Rank2     <chr> "1", "2", "4", "4", "5", "5", "6", "6", "7", "7", "8", "8", "9…
$ Pts1      <chr> "9360", "10780", "6210", "6210", "5415", "5415", "4865", "4865…
$ Pts2      <chr> "10780", "9360", "5415", "5415", "4865", "4865", "4365", "4365…
$ Odd1      <chr> "1.08", "1.25", "1.53", "1.53", "1.22", "1.22", "1.36", "1.36"…
$ Odd2      <chr> "7.00", "3.75", "2.50", "2.50", "3.75", "3.75", "3.00", "3.00"…
$ Best of   <chr> "5", "5", "5", "5", "5", "5", "5", "5", "5", "5", "5", "5", "…
$ Comment   <chr> "Completed", "Completed", "Completed", "Completed", "Completed…
```

Question 2 :

Objectif :
Importer le fichier des rencontres du tournoi masculin de Roland Garros 2013 à partir d'un fichier CSV.

Réponse :

```
rencontres <- read_csv("./data/tennis/ATP-Matches.csv")
```

```
Rows: 127 Columns: 14
```

```
glimpse(rencontres)
```

```
Rows: 127
Columns: 14
$ Player1   <chr> "Novak Djokovic", "Rafael Nadal", "Roger Federer", "Andy Murr…
$ Player2   <chr> "Rafael Nadal", "Novak Djokovic", "Andy Murray", "Roger Fede…
$ Surface   <chr> "Clay", "Clay", "Clay", "Clay", "Clay", "Clay", "Clay", "Clay…
$ Round     <chr> "Final", "Final", "Final", "Final", "Final", "Final", "Final"…
$ Tournament <chr> "Roland Garros", "Roland Garros", "Roland Garros", "Roland Ga…
$ Date      <chr> "2013-06-09", "2013-06-09", "2013-06-09", "2013-06-09", "2013…
$ Winner    <chr> "Rafael Nadal", "Novak Djokovic", "Andy Murray", "Roger Feder…
$ Score     <chr> "6-4 6-3 6-2", "6-4 7-5 6-2", "6-3 6-4 6-1", "6-3 6-4 6-1", "6…
$ Rank1     <chr> "2", "1", "3", "3", "4", "4", "5", "5", "6", "6", "7", "7", "8…
$ Rank2     <chr> "1", "2", "4", "4", "5", "5", "6", "6", "7", "7", "8", "8", "9…
$ Pts1      <chr> "9360", "10780", "6210", "6210", "5415", "5415", "4865", "4865…
$ Pts2      <chr> "10780", "9360", "5415", "5415", "4865", "4865", "4365", "4365…
$ Odd1      <chr> "1.08", "1.25", "1.53", "1.53", "1.22", "1.22", "1.36", "1.36"…
$ Odd2      <chr> "7.00", "3.75", "2.50", "2.50", "3.75", "3.75", "3.00", "3.00"…
$ Best of   <chr> "5", "5", "5", "5", "5", "5", "5", "5", "5", "5", "5", "5", "…
$ Comment   <chr> "Completed", "Completed", "Completed", "Completed", "Completed…
```

Question 3 :

Objectif :
Fusionner les deux jeux de données.

Réponse :

```
fusion <- left_join(rencontres, joueurs, by = c("Player1", "Player2"))
glimpse(fusion)
```

```
Rows: 127
Columns: 18
$ Player1   <chr> "Novak Djokovic", "Rafael Nadal", "Roger Federer", "Andy Murr…
$ Player2   <chr> "Rafael Nadal", "Novak Djokovic", "Andy Murray", "Roger Fede…
$ Surface   <chr> "Clay", "Clay", "Clay", "Clay", "Clay", "Clay", "Clay", "Clay…
$ Round     <chr> "Final", "Final", "Final", "Final", "Final", "Final", "Final"…
$ Tournament <chr> "Roland Garros", "Roland Garros", "Roland Garros", "Roland Ga…
$ Date      <chr> "2013-06-09", "2013-06-09", "2013-06-09", "2013-06-09", "2013…
$ Winner    <chr> "Rafael Nadal", "Novak Djokovic", "Andy Murray", "Roger Feder…
$ Score     <chr> "6-4 6-3 6-2", "6-4 7-5 6-2", "6-3 6-4 6-1", "6-3 6-4 6-1", "6…
$ Rank1     <chr> "2", "1", "3", "3", "4", "4", "5", "5", "6", "6", "7", "7", "8…
$ Rank2     <chr> "1", "2", "4", "4", "5", "5", "6", "6", "7", "7", "8", "8", "9…
$ Pts1      <chr> "9360", "10780", "6210", "6210", "5415", "5415", "4865", "4865…
$ Pts2      <chr> "10780", "9360", "5415", "5415", "4865", "4865", "4365", "4365…
$ Odd1      <chr> "1.08", "1.25", "1.53", "1.53", "1.22", "1.22", "1.36", "1.36"…
$ Odd2      <chr> "7.00", "3.75", "2.50", "2.50", "3.75", "3.75", "3.00", "3.00"…
$ Best of   <chr> "5", "5", "5", "5", "5", "5", "5", "5", "5", "5", "5", "5", "…
$ Comment   <chr> "Completed", "Completed", "Completed", "Completed", "Completed…
$ Rank      <chr> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA…
$ Pts       <chr> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA…
```

Question 4 :

Objectif :
Fusionner l'ensemble de la population des deux premiers prénoms masculins et féminins de l'année 2000, à partir de la série ancienne.

Réponse :

```
fusion_1 <- fusion %>
  filter(Player1 == "Novak Djokovic", Player2 == "Rafael Nadal")
glimpse(fusion_1)
```

```
Rows: 1
Columns: 18
$ Player1   <chr> "Novak Djokovic"
$ Player2   <chr> "Rafael Nadal"
$ Surface   <chr> "Clay"
$ Round     <chr> "Final"
$ Tournament <chr> "Roland Garros"
$ Date      <chr> "2013-06-09"
$ Winner    <chr> "Rafael Nadal"
$ Score     <chr> "6-4 6-3 6-2"
$ Rank1     <chr> "2"
$ Rank2     <chr> "1"
$ Pts1      <chr> "9360"
$ Pts2      <chr> "10780"
$ Odd1      <chr> "1.08"
$ Odd2      <chr> "7.00"
$ Best of   <chr> "5"
$ Comment   <chr> "Completed"
$ Rank      <chr> NA
$ Pts       <chr> NA
```

```
fusion_2 <- fusion %>
  filter(Player1 == "Rafael Nadal", Player2 == "Novak Djokovic")
glimpse(fusion_2)
```

```
Rows: 1
Columns: 18
$ Player1   <chr> "Rafael Nadal"
$ Player2   <chr> "Novak Djokovic"
$ Surface   <chr> "Clay"
$ Round     <chr> "Final"
$ Tournament <chr> "Roland Garros"
$ Date      <chr> "2013-06-09"
$ Winner    <chr> "Rafael Nadal"
$ Score     <chr> "6-4 7-5 6-2"
$ Rank1     <chr> "1"
$ Rank2     <chr> "2"
$ Pts1      <chr> "10780"
$ Pts2      <chr> "9360"
$ Odd1      <chr> "1.25"
$ Odd2      <chr> "3.75"
$ Best of   <chr> "5"
$ Comment   <chr> "Completed"
$ Rank      <chr> NA
$ Pts       <chr> NA
```

```
fusion_3 <- fusion %>
  filter(Player1 == "Roger Federer", Player2 == "Andy Murray")
glimpse(fusion_3)
```

```
Rows: 1
Columns: 18
$ Player1   <chr> "Roger Federer"
$ Player2   <chr> "Andy Murray"
$ Surface   <chr> "Clay"
$ Round     <chr> "Final"
$ Tournament <chr> "Roland Garros"
$ Date      <chr> "2013-06-09"
$ Winner    <chr> "Andy Murray"
$ Score     <chr> "6-3 6-4 6-1"
$ Rank1     <chr> "3"
$ Rank2     <chr> "4"
$ Pts1      <chr> "6210"
$ Pts2      <chr> "5415"
$ Odd1      <chr> "1.53"
$ Odd2      <chr> "2.50"
$ Best of   <chr> "5"
$ Comment   <chr> "Completed"
$ Rank      <chr> NA
$ Pts       <chr> NA
```

```
fusion_4 <- fusion %>
  filter(Player1 == "Andy Murray", Player2 == "Roger Federer")
glimpse(fusion_4)
```

```
Rows: 1
Columns: 18
$ Player1   <chr> "Andy Murray"
$ Player2   <chr> "Roger Federer"
$ Surface   <chr> "Clay"
$ Round     <chr> "Final"
$ Tournament <chr> "Roland Garros"
$ Date      <chr> "2013-06-09"
$ Winner    <chr> "Andy Murray"
$ Score     <chr> "6-3 6-4 6-1"
$ Rank1     <chr> "4"
$ Rank2     <chr> "3"
$ Pts1      <chr> "5415"
$ Pts2      <chr> "6210"
$ Odd1      <chr> "2.50"
$ Odd2      <chr> "1.53"
$ Best of   <chr> "5"
$ Comment   <chr> "Completed"
$ Rank      <chr> NA
$ Pts       <chr> NA
```

```
## 5 Jo-Wilfried Tsonga Roger Federer     5     1
```

Question 2:

Objectif :
Affichez tous les matchs de Roger Federer.

Réponse :

```
donnee_federer <- donnee |>
  select(Player1, Player2, Round, Result) |>
  filter(Player1 == "Roger Federer" | Player2 == "Roger Federer")

print(donnee_federer)
```

```
##              Player1       Player2 Round Result
## 1 Pablo Carreno-Busta Roger Federer     1      0
## 2   Dominic Thiem Roger Federer     2      0
## 3   Julien Benneteau Roger Federer     3      0
## 4         Gilles Simon Roger Federer     4      0
## 5 Jo-Wilfried Tsonga Roger Federer     5      1
```

Question 3:

Objectif :
Affichez le nom des demi-finalistes.

Réponse :

```
demi_finale <- donnee |>
  filter(Round == 5) |>
  select(Player1, Player2) |>
  distinct()

print(demi_finale)
```

```
##              Player1       Player2
## 1   David Ferrer Jo-Wilfried Tsonga
## 2 Novak Djokovic       Rafael Nadal
```

Question 4:

Objectif :
Combien y-a-t'il de point disputé par match ?

Réponse :

```
points_match <- donnee |>
  mutate(total_points = TPW.1 + TPW.2) |>
  select(Player1, Player2, Round, total_points)

print(points_match)
```

```
##              Player1       Player2 Round total_points
## 1       Pablo Carreno-Busta       Roger Federer     1          138
## 2             Dominic Thiem Daniel Munoz-De La Nava     1          226
## 3                 Tobias Kamke         Paolo Lorenzi     1          279
## 4           Julien Benneteau     Ricardas Berankis     1          312
## 5                  Lukas Lacko          Sam Querrey     1          165
## 6                   Jan Hajek           Denis Kudla     1          223
## 7             Adrian Mannarino         Pablo Cuevas     1          335
## 8                 Gilles Simon        Lleyton Hewitt     1          156
## 9             Philipp Petzschner          Marin Cilic     1          246
## 10              Radek Stepanek         Nick Kyrgios     1          262
## 11                Viktor Troicki          James Blake     1          150
## 12                   Juan Monaco   Daniel Gimeno-Traver     1          351
## 13             Benjamin Becker         Jeremy Chardy     1          193
## 14   Roberto Bautista Agut          Gilles Muller     1          175
## 15          Jarkko Nieminen   Paul-Henri Mathieu     1          335
## 16           Jo-Wilfried Tsonga          Aljaz Bedene     1          156
## 17             Marinko Matosevic         David Ferrer     1          174
## 18                 Steve Johnson       Albert Montanes     1          260
## 19                  Joao Sousa            Go Soeda     1          144
## 20              Marcel Granollers     Feliciano Lopez     1          254
## 21                 Iliya Marchenko       Kevin Anderson     1          204
## 22            Jan-Lennard Struff       Evgeny Donskoy     1          264
## 23                 Steve Darcis       Michael Llodra     1          243
## 24                 Milos Raonic       Xavier Malisse     1          203
## 25   Andreas Haider-Maurer       Nicolas Almagro     1          212
## 26                  Martin Klizan   Edouard Roger-Vasselin     1          194
## 27                   Blaz Kavcic         James Duckworth     1          139
## 28                 Andreas Seppi         Leonardo Mayer     1          325
## 29                   Jurgen Zopp          Tommy Robredo     1          153
## 30                 Igor Sijsling         Jurgen Melzer     1          165
## 31               Ernesta Gulbis   Rogerio Dutra Silva     1          171
## 32                  Tomas Berdych          Gael Monfils     1          363
## 33             Sergiy Stakhovsky       Richard Gasquet     1          145
## 34              Michal Przysiezny         Rhyne Williams     1          285
## 35                 Florent Serra       Nikolay Davydenko     1          171
## 36                 Florian Mayer          Denis Istomin     1          188
## 37                 Albert Ramos         Jerzy Janowicz     1          207
## 38              Kenny De Schepper           Robin Haase     1          256
## 39                 Vasek Pospisil       Horacio Zeballos     1          276
## 40              Stanislas Wawrinka       Thiemo De Bakker     1          281
## 41                   Jesse Levine          Kei Nishikori     1          135
## 42                  Grega Zemlja       Santiago Giraldo     1          154
## 43                  Lukasz Kubot         Maxime Teixeira     1          175
## 44                  Benoit Paire        Marcos Baghdatis     1          205
## 45                 Andreas Beck           Fabio Fognini     1          231
## 46                      Peru Riba           Lukas Rosol     1          179
## 47                 Martin Klizan       Michael Russell     1          173
## 48                 Rafael Nadal          Daniel Brands     1          255
## 49              Fernando Verdasco           Marc Gicquel     1          147
## 50             Federico Delbonis         Julian Reister     1          219
## 51                Mikhail Youzhny          Pablo Andujar     1          280
## 52                 Carlos Berlocq           John Isner     1          189
## 53               Andrey Kuznetsov         Ryan Harrison     1          205
## 54                     Jack Sock   Guillermo Garcia-Lopez     1          163
## 55                   Tommy Haas       Guillaume Rufin     1          179
## 56                   Jiri Vesely   Philipp Kohlschreiber     1          252
## 57                  Simone Bolelli           Yen-Hsun Lu     1          135
## 58                 Bernard Tomic         Victor Hanescu     1          194
## 59             Alexandr Dolgopolov       Dmitry Tursunov     1          235
## 60                 Alejandro Falla       Grigor Dimitrov     1           86
## 61                   Alex Kuznetsov         Lucas Pouille     1          193
## 62                      Ivan Dodig           Guido Pella     1          351
## 63                 Novak Djokovic         David Goffin     1          213
## 64                 Dominic Thiem         Roger Federer     2          140
## 65                 Julien Benneteau         Tobias Kamke     2          357
## 66                      Jan Hajek          Sam Querrey     2          195
## 67                 Gilles Simon         Pablo Cuevas     2          215
## 68                 Nick Kyrgios          Marin Cilic     2          149
## 69             Daniel Gimeno-Traver         Viktor Troicki     2          342
## 70             Roberto Bautista Agut         Jeremy Chardy     2          181
## 71             Jo-Wilfried Tsonga         Jarkko Nieminen     2          189
## 72                 Albert Montanes         David Ferrer     2          159
## 73                 Feliciano Lopez           Joao Sousa     2          238
## 74                 Evgeny Donskoy       Kevin Anderson     2          268
## 75                 Milos Raonic       Michael Llodra     2          271
## 76   Edouard Roger-Vasselin       Nicolas Almagro     2          176
## 77                 Andreas Seppi          Kei Nishikori     2          333
## 78                 Igor Sijsling         Tommy Robredo     2          239
## 79                 Gael Monfils         Ernesta Gulbis     2          271
## 80               Michal Przysiezny       Richard Gasquet     2          145
## 81                 Denis Istomin       Nikolay Davydenko     2          182
## 82                  Robin Haase         Jerzy Janowicz     2          239
## 83              Stanislas Wawrinka       Horacio Zeballos     2          201
## 84                  Grega Zemlja          Kei Nishikori     2          245
## 85                  Benoit Paire           Lukasz Kubot     2          184
## 86                  Lukas Rosol           Fabio Fognini     2          236
## 87                 Rafael Nadal          Martin Klizan     2          203
## 88              Fernando Verdasco       Janko Tipsarevic     2          381
## 89                Mikhail Youzhny     Federico Delbonis     2          288
## 90                 Ryan Harrison           John Isner     2          343
## 91                   Tommy Haas           Jack Sock     2          212
## 92                Dmitry Tursunov         Victor Hanescu     2          128
## 93                  Lucas Pouille       Grigor Dimitrov     2          174
## 94                 Novak Djokovic           Guido Pella     2          351
## 95               Julien Benneteau         Roger Federer     3          162
## 96                 Gilles Simon          Sam Querrey     3          267
## 97                Viktor Troicki          Marin Cilic     3          243
## 98             Jo-Wilfried Tsonga         Jeremy Chardy     3          166
## 99                 Feliciano Lopez         David Ferrer     3          191
## 100                Milos Raonic       Kevin Anderson     3          228
## 101                Andreas Seppi       Nicolas Almagro     3          181
## 102                 Gael Monfils         Tommy Robredo     3          224
## 103              Nikolay Davydenko       Richard Gasquet     3          184
## 104             Stanislas Wawrinka         Jerzy Janowicz     3          252
## 105                Benoit Paire          Kei Nishikori     3          256
## 106                Rafael Nadal           Fabio Fognini     3          233
## 107               Mikhail Youzhny       Janko Tipsarevic     3          173
## 108                   Tommy Haas           John Isner     3          437
## 109                Victor Hanescu   Philipp Kohlschreiber     3          176
## 110                Novak Djokovic       Grigor Dimitrov     3          155
## 111                 Gilles Simon         Roger Federer     4          278
## 112             Jo-Wilfried Tsonga         Viktor Troicki     4          168
## 113                Kevin Anderson         David Ferrer     4          157
## 114                Tommy Robredo       Nicolas Almagro     4          334
## 115             Stanislas Wawrinka       Richard Gasquet     4          369
## 116                 Rafael Nadal          Kei Nishikori     4          156
## 117                   Tommy Haas       Mikhail Youzhny     4          336
## 118                Novak Djokovic   Philipp Kohlschreiber     4          257
## 119             Jo-Wilfried Tsonga         Roger Federer     5          176
## 120                Tommy Robredo         David Ferrer     5          130
## 121                 Rafael Nadal       Stanislas Wawrinka     5          160
## 122                Novak Djokovic           Tommy Haas     5          200
## 123                 David Ferrer       Jo-Wilfried Tsonga     6          191
## 124                Novak Djokovic           Rafael Nadal     6          335
## 125                 Rafael Nadal         David Ferrer     7          172
```

Interprétation :
Le total de points par match renseigne sur l'intensité des rencontres.
Un nombre élevé de points traduit souvent une forte compétitivité et des matchs serrés.

Question 5:

Objectif :
Regardons maintenant les aces. Pour chaque tour, affichez le plus petit nombre, le plus grand et le nombre moyen de ace effectué par l'ensemble des deux joueurs.

Réponse :

```
aces_stats <- donnee |>
  mutate(total_aces = ACE.1 + ACE.2) |>
  group_by(Round) |>
  summarise(
    min_aces = min(total_aces, na.rm = TRUE),
    max_aces = max(total_aces, na.rm = TRUE),
    moyen_aces = mean(total_aces, na.rm = TRUE)
  )

print(aces_stats)
```

```
## # A tibble: 7 × 4
##   Round min_aces max_aces moyen_aces
##   <int>   <int>   <int>      <dbl>
## 1     1       3      37       13.5
## 2     2       2      38       13.2
## 3     3       2      42       12.6
## 4     4       1      23        9.12
## 5     5       2      15        7
## 6     6       9      11       10
## 7     7       6       6        6
```

Question 6:

Objectif :
Combien y-a-t'il eu de doubles fautes dans le tournoi.

Réponse :

```
total_doubles_fautes <- donnee |>
  summarise(total_DBF = sum(DBF.1 + DBF.2, na.rm = TRUE))

print(total_doubles_fautes)
```

```
##   total_DBF
## 1       612
```

Question 7:

Objectif :
Faites un histogramme (geom_histl) du nombre de double faute par match.

Réponse :

```
donnee |>
  mutate(total_DBF = DBF.1 + DBF.2) |>
  filter(!is.na(total_DBF)) |>
  ggplot(aes(x = total_DBF)) +
  geom_histogram(binwidth = 1, fill = "steelblue", color = "white") +
  labs(
    title = "Distribution des doubles fautes par match",
    subtitle = "Analyse du nombre de doubles fautes réalisées dans l'ensemble du tournoi",
    x = "Nombre total de doubles fautes par match",
    y = "Nombre de matchs"
  )
```

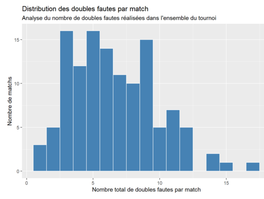

Interprétation :
La distribution des doubles fautes par match est généralement concentrée autour de valeurs faibles.
Cela suggère une bonne maîtrise technique du service chez la majorité des joueurs.

Question 8:

Objectif :
Représentez l'évolution du nombre moyen de doubles fautes par match au cours des différents tours.

Réponse :

```
evolution_doubles <- donnee |>
  mutate(total_DBF = DBF.1 + DBF.2) |>
  filter(!is.na(total_DBF)) |>
  group_by(Round) |>
  summarise(mean_DBF = mean(total_DBF))

ggplot(evolution_doubles, aes(x = Round, y = mean_DBF, group = 1)) +
  geom_line(color = "steelblue", linewidth = 1) +
  geom_point(color = "red", size = 3) +
  labs(
    title = "Évolution des doubles fautes par tour",
    subtitle = "Nombre moyen de doubles fautes par match au fil des tours de Roland Garros 2013",
    x = "Tour du tournoi (1 = 1er tour, 7 = finale)",
    y = "Nombre moyen de doubles fautes par match"
  )
```

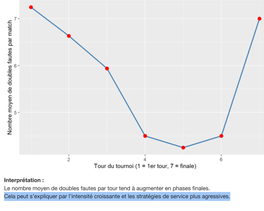

Interprétation :
Le nombre moyen de doubles fautes par tour tend à augmenter en phases finales.
Cela peut s'expliquer par l'intensité croissante et les stratégies de service plus agressives.